

大規模言語モデルによるソフトウェア脆弱性の検出

高知大学 理工学部情報科学科 横川武典

1. 研究背景

言語モデルがコード生成やデバッグ等に活用

→ 生成されるコードの**安全は担保されていない**

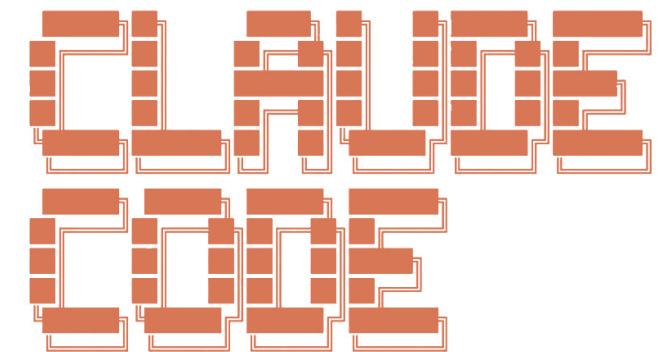


図1. コーディングに使われる言語モデルが含まれるツールの例

2. 研究目的

言語モデルで脆弱性を自動で検知

以下2つの問題に対応可能

1. 言語モデルが生成したコードは安全と限らない

→ コードに自動で脆弱性の検知を行い安全性を確保

2. 脆弱性を発見にはテストやコードレビューが必要

→ 手間の削減が可能

3. 関連研究 [Sheng+2025]

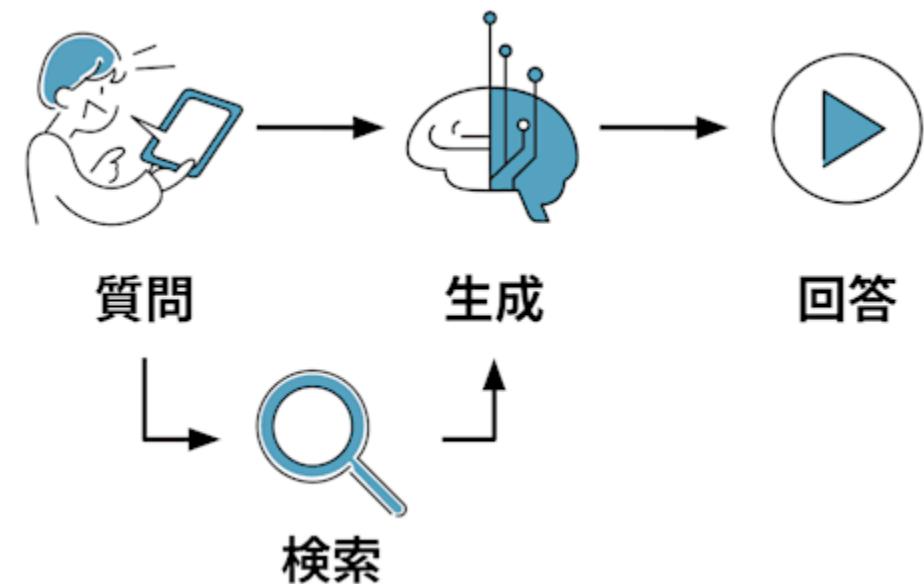
- コードの断片から脆弱性を検出できる言語モデルが存在
- リポジトリ単位では限定的な脆弱性の検出のみ可能
- メモリ関連の脆弱性は検出精度が高い
- C/C++に関する研究が多い

4. 研究手法

1. 脆弱性のデータベースを取得/作成
2. データベースを元に**RAG**の作成/**FineTuning**
 - データベースを参照/学習に使う
3. ソースコードから脆弱性を探す
 - 既存のソースコード
 - 言語モデルの生成したソースコード

RAG(Retrieval-Augmented Generation)とは

- RAGは事前学習していない**外部知識を参照**しその情報に基づいて文章を生成する手法
- 以下の3段階で機能する
 1. クエリと**類似する情報を**データベースから参照
 2. **得られた情報を**入力に追加
 3. LLMで入力から推論



FineTuningとは

- 既存の学習済みモデルに、追加の学習を行い特定のタスク用に調整
- メリットは以下の3つ
 - 一から学習しないためコストが安い
 - 最新の情報への対応
 - 特定の用途に特化したモデルを作成可

5. 現状の進捗

5-1. データの取得

- 脆弱性情報を管理するJVN/CVEから収集した脆弱性情報を元にデータベースを構築
- WordPressに関する脆弱性を取得しjsonで保管

```
"JVNDDB-2025-009951": {  
    "title": "AntoineH の WordPress 用 Football Pool における...",  
    "description": "The Football Pool plugin for WordPress is ...",  
    "technologies": "AntoineH Football Pool 2.12.5 未満"  
},
```

図2. 脆弱性データベースの一例

5-2. 脆弱性の発見

- 調整していない言語モデルに脆弱性を探させてみる
 - 検証に使ったソースコードは"chatGPT-4o mini"で生成
1. オンラインのモデルとして"chatGPT-4o mini"を利用
生成したphpのコード全文から脆弱性を探す
→ 簡単なコードの脆弱性は検出/修正可
 2. ローカルのモデルとして"gpt-oss-20B"を利用
生成したphpのコード全文から脆弱性を探す
→ 結果は出力が不安定になることが大半

6. 今後の課題

1. 入力長が長くても安定した出力を得られる言語モデルを探す
2. 脆弱性情報を元に言語モデルを**FineTuning**
または**RAG**等を作成し言語モデルが情報を参照可能に
3. どの程度の脆弱性を発見できるか調査

参考文献

- LLMs in Software Security: A Survey of Vulnerability Detection Techniques and Insights [Ze Sheng+2025]
<https://arxiv.org/html/2502.07049v2>
- JVN iPedia - 脆弱性対策情報データベース
<https://jvndb.jvn.jp/>
- CVE: Common Vulnerabilities and Exposures
<https://www.cve.org/CVERecord>

Appendix A. WEB言語の脆弱性の傾向

2022年に脆弱性が悪用された技術としてWordPressがトップ
全体の1/4を占めた



WordPress	24.4%
IBM Web Sphere	7.7%
Joomla	14.6%
Apache Server	6.2%
Apache Struts	12.6%
Magento	5.7%
cPanel	9.8%
Nagios	5.5%
Apache Log4j	8.4%
Zoho Manage Engine	5.1%

Appendix B. データベースからFineTuning/RAGを作成する手法

- RAGを作成する場合
自然言語で書かれた脆弱性のデータベースをベクトルに変換
この処理はPythonの"LangChain"等のライブラリを使用
- FineTuningの場合
オープンソースで公開されている言語モデルに脆弱性の
データベースで追加学習
この処理はPythonの"unslloth", "trl"等のライブラリを使用

Appendix C. ローカルで動作する言語モデルの不安定な出力

- gpt-oss-20b

10回応答を生成して、問題を検出できたのは1度のみ
クロスサイトリクエストフォージェリx1

```
<|end|><|start|>assistant!!!! for.  
You `` might. be Let's your.. the0..  
a let's  
theLet's.. be1.  
the. . to!. Let's e this.. e .?
```

- Qwen3-14B
 - 10回応答を生成して、問題を検出できたのは7回
 - セッションハイジャックx1
 - クロスサイトリクエストフォージェリx7

```
But the results section is only displayed if $results is not empty.  
:  
the code doesn't display the results section again because $re  
$  
↑最終的な出力に移らず終了する
```